

Ejercicio Entregable, TP Integrador

Iacobucci, Juan Bautista

Prieto, Alán Daniel

Terechovich, Agustin

UNLP, Informática

1. Introducción

El presente trabajo se enmarca en la aplicación de técnicas de análisis de datos al ámbito deportivo. En particular, se busca abordar un problema de predicción dentro del fútbol profesional, donde la disponibilidad de datos históricos permite modelar comportamientos complejos asociados al rendimiento de equipos y jugadores.

En este trabajo nos enfocaremos en tres objetivos generales:

1. Identificar perfiles o arquetipos de jugadores mediante técnicas de clustering, agrupándolos según sus atributos técnicos y físicos.
2. Desarrollar un modelo de clasificación que permita predecir el resultado de un partido (victoria local, empate o victoria visitante) a partir de las características de los equipos involucrados.
3. Construir un modelo de regresión para estimar atributos de rendimiento de un jugador en función de su perfil físico y su posición.

2. Descripción del Dominio

El fútbol es un deporte de conjunto disputado entre dos equipos de 11 jugadores cada uno, con el objetivo de introducir el balón en el arco rival. Un partido se divide en dos tiempos de 45 minutos, y el equipo que marca más goles al finalizar el tiempo reglamentario gana. En caso de igualdad, el resultado se registra como empate, salvo en instancias eliminatorias donde se recurre a tiempos extra o penales.

Cada equipo dispone de un arquero y diez jugadores de campo, organizados según una formación táctica que distribuye defensores, mediocampistas y delanteros. La elección de la formación y el estilo de juego (ya sea de posesión, contraataque o presión alta) son decisiones del cuerpo técnico que impactan directamente en el rendimiento del equipo.

El fútbol profesional europeo está organizado principalmente en ligas nacionales, donde los clubes compiten durante una temporada completa bajo el formato de todos contra todos. Las ligas más conocidas son la Premier League (Inglaterra), La Liga (España), la Bundesliga (Alemania), la Serie A (Italia) y la Ligue 1 (Francia). A nivel continental, la UEFA organiza la Champions League y la Europa League, aunque estas competencias no forman parte del dataset analizado. Cada liga es regulada por su federación nacional, bajo los lineamientos generales de la FIFA a nivel mundial y la UEFA a nivel europeo.

Un concepto relevante para este trabajo es la valoración de jugadores mediante videojuegos: EA Sports, desarrolladora de la saga FIFA, asigna a cada jugador real un conjunto de atributos numéricos (como velocidad, regate, pase, disparo o defensa) que buscan reflejar su nivel real de juego. Estas valoraciones, actualizadas semanalmente, constituyen una fuente de datos ampliamente utilizada en análisis deportivos por su cobertura y granularidad.

3. Descripción del Conjunto de Datos

3.1. Caracterización Técnica

La base de datos original tiene una estructura relacional compuesta por 7 tablas (DataFrames), las cuales engloban un total de variables que abarcan desde metadatos hasta estadísticas avanzadas de juego. A continuación, se detallan sus atributos principales:

- **Country (1 atributo) y League (2 atributos):** Contienen el identificador único del país (*country_id* en la tabla League) y los nombres de los países y ligas europeas (*name*).
- **Team (4 atributos):** Almacena los datos identificatorios de los equipos (*team_api_id*, *team_fifa_api_id*) junto con el nombre completo (*team_long_name*) y la abreviación (*team_short_name*).
- **Player (6 atributos):** Detalla el perfil demográfico y físico de cada jugador. Incluye IDs (*player_api_id*, *player_fifa_api_id*), nombre (*player_name*), fecha de nacimiento (*birthday*), altura en cm (*height*) y peso en libras (*weight*).
- **Team_Attributes (24 atributos):** Contiene evaluaciones tácticas de los equipos en fechas específicas (*date*). Se compone de variables numéricas y clases categóricas sobre la velocidad de construcción de juego (*buildUpPlaySpeed*), pases, creación de oportunidades mediante cruces o tiros (*chanceCreationShooting*), y parámetros defensivos como presión y agresividad (*defencePressure*, *defenceAggression*).
- **Player_Attributes (41 atributos):** Es el núcleo del rendimiento técnico individual extraído del videojuego FIFA. Además de las fechas y claves (*player_api_id*, *player_fifa_api_id*), abarca métricas numéricas (escala 0-100) como valoración general (*overall_rating*), potencial (*potential*), ritmo (*sprint_speed*), precisión

(*finishing, short_passing*), físico (*stamina, strength*) y reflejos de portero (*gk_diving*). Incluye atributos categóricos como la pierna hábil (*preferred_foot*) y la tasa de trabajo ofensivo/defensivo (*attacking_work_rate*).

- **Match (114 atributos):** Es la tabla más densa con casi 26.000 encuentros. Agrupa sus columnas de la siguiente manera:
 - *Metadatos e IDs (6 columnas):* Temporada, fecha, identificadores de liga y de los equipos locales y visitantes (ej. *match_api_id*).
 - *Resultados (2 columnas):* Goles del equipo local (*home_team_goal*) y visitante (*away_team_goal*).
 - *Alineaciones y Coordinadas (44 columnas):* Identificadores de los 11 jugadores de cada equipo (*home_player_1* a *11*), así como sus posiciones X e Y en el campo de juego.
 - *Eventos del partido (8 columnas):* Formato de texto/XML con el desglose de posesión, goles, tiros, faltas y tarjetas (*goal, card, possession*, etc.).
 - *Cuotas de apuestas (30 columnas):* Probabilidades de victoria local (H), empate (D) y visitante (A) de múltiples casas de apuestas como Bet365 (*B365H*), Bwin (*BWH*), y Pinnacle (*PSH*).

La descripción de atributos detallada, los tipos de datos y los ejemplos de las 7 tablas pueden consultarse en el Anexo al final del documento.

3.2. Metodología de Recolección

El conjunto de datos utilizado, denominado "[European Soccer Database](#)", es una base de datos de acceso público obtenida a través de la plataforma Kaggle. Este repositorio fue

construido mediante la integración de información proveniente de múltiples fuentes dispersas en la web, requiriendo un exhaustivo proceso de recopilación y procesamiento (crawling/scraping) mediante scripts automatizados en Python.

El origen de los datos se segmenta principalmente en tres fuentes distintas:

1. **Eventos y Alineaciones:** Los resultados, formaciones de los equipos y eventos detallados del partido (goles, posesión, tarjetas, etc.) fueron extraídos de la API y el portal web de estadísticas deportivas *football-data.mx-api.enetscores.com*.
2. **Cuotas de Apuestas:** La información sobre las probabilidades (betting odds) proporcionadas por hasta 10 casas de apuestas diferentes fue recopilada del portal *football-data.co.uk*.
3. **Atributos de Jugadores y Equipos:** Las métricas físicas, técnicas y tácticas fueron obtenidas mediante técnicas de scraping aplicadas sobre el sitio *sofifa.com*, el cual actúa como un repositorio de las estadísticas oficiales utilizadas en la saga de videojuegos "FIFA" de la empresa EA Sports.

Sesgos Potenciales y Problemas de Recolección

El análisis del proceso de recolección revela ciertas limitaciones y sesgos inherentes a la forma en que los datos fueron construidos:

- **Sesgo de Subjetividad en Atributos Técnicos:** Al depender de las bases de datos del videojuego FIFA (EA Sports), las habilidades de los jugadores y las métricas tácticas de los equipos no son mediciones empíricas estrictas, sino evaluaciones subjetivas realizadas por "scouts" y desarrolladores del juego. Aunque son ampliamente


aceptadas como aproximaciones válidas en el dominio deportivo, introducen un sesgo humano en las variables predictivas.

- **Pérdida de Datos por Sincronización:** El autor del dataset señala explícitamente problemas en la integración de las fuentes. Existen jugadores ausentes en las alineaciones (valores NULL) debido a fallos del algoritmo de "crawling" al intentar emparejar los registros de los partidos reales con la base de datos de *sofifa.com*.

3.3. Análisis Inicial


Un análisis preliminar sobre el conjunto de datos revela una distribución dispar en los valores faltantes. Por un lado, las tablas como Country, League y Player poseen el 100% de sus registros completos. Otras, como Team o las estadísticas numéricas de Player Attributes, presentan vacíos muy reducidos (aproximadamente 800 faltantes sobre un total de 183.978 registros).

Sin embargo, se detectó una pérdida de información sistemática en la tabla Match. Todos los atributos correspondientes a los **Eventos del partido** (tales como goal, shot on, card y possession) presentan exactamente 11.762 valores nulos. Asimismo, las variables correspondientes a las **Cuotas de apuestas** fluctúan severamente dependiendo de la cobertura de cada proveedor (por ejemplo, la casa de apuestas Pinnacle carece de más del 50% de sus datos históricos).



Para un primer análisis sobre el conjunto de datos, se inspeccionaron los posibles valores atípicos mediante diagramas de caja (Boxplots) y estadísticos descriptivos.

En cuanto a las **Estadísticas de Habilidad y Táctica** (Player Attributes y Team Attributes), la integración con la base de datos del videojuego FIFA aporta una serie de datos previamente analizados por la desarrolladora del videojuego: todos los atributos numéricos de rendimiento están rígidamente limitados en una escala de 0 a 100. Al graficar estas distribuciones, se observan outliers desde el punto de vista estrictamente estadístico (por ejemplo, jugadores con un ritmo o precisión excepcionalmente altos o bajos); sin embargo, todos son valores reales y válidos dentro de la lógica del dominio deportivo. Por lo tanto, representan el talento excepcional (o la falta del mismo) de ciertos deportistas y no deben ser eliminados ni considerados como ruido perjudicial para el entrenamiento de los modelos.



Al observar detenidamente el diagrama de caja de las habilidades individuales, destaca un patrón particular: la presencia de una densa concentración de valores atípicos superiores en los últimos cinco atributos del gráfico (correspondientes a `gk_diving`, `gk_handling`, `gk_kicking`, `gk_positioning` y `gk_reflexes`). Dichas métricas evalúan exclusivamente el desempeño de los arqueros. Debido a que la proporción natural de porteros frente a jugadores de campo es de aproximadamente 1 a 10, la inmensa mayoría del dataset presenta puntajes mínimos (cerca de 10) en estas habilidades, lo que empuja la media y los cuartiles hacia abajo. En consecuencia, las valoraciones de los verdaderos arqueros son interpretadas matemáticamente por el gráfico como valores atípicos.

Se hizo un trabajo de preprocesamiento sobre la tabla de Match, que cuenta con un total de **25.979 registros**. Para las diferentes técnicas de análisis, se decidió eliminar todas las columnas con registros nulos, o las columnas que no fueran relevantes para el análisis de esa estrategia para luego volver a eliminar las columnas incompletas.

Si bien se generó una visualización de la cantidad de ausencias, su extensión (superior a las 115 columnas), se dificulta la representación gráfica legible dentro de este informe de todos los datos eliminados. Por ello, se describen a continuación cada uno de estos atributos.

- **Variables de Alineación:** Los identificadores de jugadores (ej. home_player_1 a home_player_11) presentan una ausencia de entre **1.224 y 2.532 registros** (aprox. 5% - 10%). Esto indica partidos donde la hoja de alineación no fue digitalizada correctamente.
- **Variables de Mercado (Apuestas):** Mientras que operadores líderes como **Bet365 (B365H)** tienen **3.387 nulos (13%)**, otros operadores como **Gamebookers (GBH)** o **Stan James (SJH)** alcanzan cifras alarmantes de **11.817 (45,4%)** y **13.130 (50,5%)** nulos respectivamente.

La predominancia de nulos en estos atributos responde a tres factores fundamentales:

1. **Contexto Temporal (2008-2016):** En las temporadas iniciales (2008-2010), la recolección de metadatos no era tan exhaustiva. Por ejemplo, la cobertura de cuotas de apuestas es mucho más fragmentada en los primeros 3 años del dataset.
2. **Disponibilidad de Operadores:** Muchas casas de apuestas incluidas en el dataset, como SJH o GB, no operaban en todas las ligas europeas o, en algunos casos, cesaron

actividades o fueron absorbidas antes de finalizar el periodo de toma de datos en 2016.

3. **Sesgo de Ligas:** Existe una disparidad notable entre las ligas "Top 5" de Europa y ligas menores (ej. Polonia o Bélgica), donde las agencias de apuestas suelen tener una cobertura limitada.


Una presencia de casi el 50% de nulos en variables de apuestas impide el uso de técnicas de imputación simples (como la media), ya que se introduciría un sesgo artificial masivo. Por consiguiente, se ha determinado descartar las columnas con más del 30% de nulos y priorizar el uso de variables con mayor integridad como B365 para el entrenamiento del modelo de clasificación de resultados.

4. Análisis Exploratorio Inicial (EDA)


Predicción por Cuota de Apuesta

Siguiendo el objetivo de predecir el ganador de un encuentro, se analizó la variable objetivo resultado y su relación con los atributos de mercado.


Al clasificar los resultados en Victoria Local, Empate y Victoria Visitante, observamos un sesgo marcado hacia la localía.





Para afinar la selección de atributos, se analizó el comportamiento de las cuotas. Al observar el diagrama de caja (*boxplot*) de la cuota B365H, se evidencia que en los partidos que finalizaron en victoria local, el valor de la mediana de estas cuotas es significativamente más bajo (1.85) en comparación con las medianas observadas en los empates o derrotas.



Este patrón de "cuota baja = alta probabilidad" es consistente en todas las casas de apuestas analizadas, para el caso y por la proporción de datos nulos presentes en la mayoría de casas de apuestas decidimos tomar a las 3 con más datos, excluyendo B365 que es la que más posee y sera con la cual continuaremos el análisis posterior. Lo que confirma que las cuotas son predictores robustos y uniformes entre proveedores.




El uso de cuotas como variable de entrada permite capturar una 'inteligencia colectiva' que eleva la tasa de acierto. Al segmentar los partidos por rangos de cuotas, se observa que a menor cuota asignada al local, el Win Rate efectivo aumenta. Utilizar la cuota mínima como criterio de decisión es fundamental para el éxito del modelo. El mismo se mide por su capacidad de alcanzar el umbral de rentabilidad del 54.05%. Este valor representa el punto de equilibrio (*breakeven*) matemático para una cuota estándar de 1.85, calculado mediante la probabilidad implícita¹ ($1 / 1.85$). Superar este porcentaje de acierto es el objetivo final de este trabajo, ya que implica que el algoritmo no solo predice mejor que el azar, sino que es capaz de neutralizar la comisión de la casa de apuestas y generar una ganancia neta.



¹ La **probabilidad implícita** es la conversión de la cuota de una casa de apuestas en un porcentaje que representa la probabilidad de que ocurra un evento según el mercado. Se calcula con la fórmula: $1 / \text{Cuota}$. Este valor define el punto de equilibrio (*breakeven*): para obtener ganancias netas, un algoritmo debe lograr una tasa de acierto superior a esta probabilidad.

Analisis de Goles por Cuota de Apuesta

En primera instancia, se hace un análisis descriptivo de los goles convertidos. En promedio, el equipo local anota 1.545 goles por partido frente a los 1.161 del visitante, lo que representa una superioridad del 33% en la producción goleadora.



Métrica	Local	Visitante	Diferencia
Media de goles	1.545	1.161	+0.384
Mediana de goles	1.0	1.0	0.0
Desv. Estándar	1.297	1.142	0.155


La distribución por rangos refuerza esta tendencia: el equipo visitante termina sin marcar (0 goles) en el 33.44% de los encuentros, mientras que el local solo lo hace en el 22.70%. Asimismo, en la producción de 2 o más goles, el local domina con un 37% de

frecuencia frente al 28% del visitante. Esta disparidad válida la localía como una característica importante para el modelo de clasificación.

En un segundo paso, se cruzó la expectativa del mercado (representada por la cuota B365H) con la eficiencia goleadora real del equipo local.

El gráfico de dispersión revela una curva de interpolación negativa: a medida que la cuota disminuye (indicando un mayor favoritismo del local), la cantidad de goles anotados tiende a aumentar. La línea de tendencia suavizada captura esta relación no lineal, mostrando una mayor densidad de "goleadas" (3 o más goles) en cuotas inferiores a la mediana de 1.85.

Se puede confirmar que las cuotas de apuestas no solo resumen la probabilidad de ganar, sino que son un indicador indirecto del potencial ofensivo de un equipo.



Anexo: Diccionario de Datos**Country**

Atributo	Tipo de Dato	Ejemplo de Valor
name	Object (String)	Belgium'

League

Atributo	Tipo de Dato	Ejemplo de Valor
country_id	Int64	1
name	Object (String)	Belgium Jupiler League'

Team

Atributo	Tipo de Dato	Ejemplo de Valor
team_api_id	Int64	9987
team_fifa_api_id	Float64	673.0
team_long_name	Object (String)	KRC Genk'
team_short_name	Object (String)	GEN'

Player

Atributo	Tipo de Dato	Ejemplo de Valor
player_api_id	Int64	505942
player_name	Object (String)	Aaron Appindangoye'
player_fifa_api_id	Float64	218353.0
birthday	Object (String/Date)	1992-02-29 00:00:00'
height	Float64	182.88
weight	Int64	187

Team_Attributes

Atributo	Tipo de Dato	Ejemplo de Valor
team_fifa_api_id	Float64	434.0
team_api_id	Int64	9930
date	Object (String/Date)	2010-02-22 00:00:00'
buildUpPlaySpeed	Int64	60
buildUpPlaySpeedClass	Object (String)	Balanced'
buildUpPlayDribbling	Float64	50.0 (o NaN)
buildUpPlayDribblingClass	Object (String)	Little'
buildUpPlayPassing	Int64	50
buildUpPlayPassingClass	Object (String)	Mixed'
buildUpPlayPositioningClass	Object (String)	Organised'
chanceCreationPassing	Int64	60
chanceCreationPassingClass	Object (String)	Normal'
chanceCreationCrossing	Int64	65
chanceCreationCrossingClass	Object (String)	Normal'
chanceCreationShooting	Int64	55
chanceCreationShootingClass	Object (String)	Normal'
chanceCreationPositioningClass	Object (String)	Organised'
defencePressure	Int64	50
defencePressureClass	Object (String)	Medium'
defenceAggression	Int64	55
defenceAggressionClass	Object (String)	Press'
defenceTeamWidth	Int64	45
defenceTeamWidthClass	Object (String)	Normal'
defenceDefenderLineClass	Object (String)	Cover'

Player_Attributes

Atributo	Tipo de Dato	Ejemplo de Valor
player_fifa_api_id	Float64	218353.0

player_api_id	Int64	505942
date	Object (String/Date)	2016-02-18 00:00:00'
overall_rating	Float64	67.0
potential	Float64	71.0
preferred_foot	Object (String)	right'
attacking_work_rate	Object (String)	medium'
defensive_work_rate	Object (String)	medium'
crossing	Float64	49.0
finishing	Float64	44.0
heading_accuracy	Float64	71.0
short_passing	Float64	61.0
volleys	Float64	44.0
dribbling	Float64	51.0
curve	Float64	45.0
free_kick_accuracy	Float64	39.0
long_passing	Float64	64.0
ball_control	Float64	49.0
acceleration	Float64	60.0
sprint_speed	Float64	64.0
agility	Float64	59.0
reactions	Float64	47.0
balance	Float64	65.0
shot_power	Float64	55.0
jumping	Float64	58.0
stamina	Float64	54.0
strength	Float64	76.0
long_shots	Float64	35.0
aggression	Float64	71.0
interceptions	Float64	70.0
positioning	Float64	45.0
vision	Float64	54.0

penalties	Float64	48.0
marking	Float64	65.0
standing_tackle	Float64	69.0
sliding_tackle	Float64	69.0
gk_diving	Float64	6.0
gk_handling	Float64	11.0
gk_kicking	Float64	10.0
gk_positioning	Float64	8.0
gk_reflexes	Float64	8.0

Matches

Atributo(s)	Tipo de Dato	Ejemplo de Valor
country_id	Int64	1
league_id	Int64	1
season	Object (String)	2008/2009'
stage	Int64	1
date	Object (String/Date)	2008-08-17 00:00:00'
match_api_id	Int64	492473
home_team_api_id	Int64	9987
away_team_api_id	Int64	9993
home_team_goal	Int64	1
away_team_goal	Int64	1
home_player_X1 a home_player_X11 (11 columnas: Coordenadas X locales)	Float64	1.0 (Arquero), 2.0 (Defensa), etc.
away_player_X1 a away_player_X11 (11 columnas: Coordenadas X visitantes)	Float64	1.0, 4.0, 6.0, etc.

home_player_Y1 a home_player_Y11 (11 columnas: Coordenadas Y locales)	Float64	1.0 (Arquero), 3.0 (Defensa), etc.
away_player_Y1 a away_player_Y11 (11 columnas: Coordenadas Y visitantes)	Float64	1.0, 3.0, 7.0, etc.
home_player_1 a home_player_11 (11 columnas: IDs jugadores locales)	Float64	39890.0, 38788.0, etc.
away_player_1 a away_player_11 (11 columnas: IDs jugadores visitantes)	Float64	38327.0, 67950.0, etc.
goal, shoton, shutoff (Eventos de Goles y Tiros)	Object (XML String)	<goal><value><stats>...
foulcommit, card (Faltas y Tarjetas)	Object (XML String)	<card><value><comment> ...
cross, corner, possession (Centros, Córners y Posesión)	Object (XML String)	<possession><value>...
B365H, B365D, B365A (Cuotas Bet365: Local, Empate, Visita)	Float64	H: 1.73, D: 3.40, A: 5.00
BWH, BWD, BWA (Cuotas Bet&Win)	Float64	H: 1.75, D: 3.35, A: 4.20
IWH, IWD, IWA (Cuotas Interwetten)	Float64	H: 1.85, D: 3.20, A: 3.50
LBH, LBD, LBA (Cuotas Ladbrokes)	Float64	H: 1.80, D: 3.30, A: 3.75
PSH, PSD, PSA (Cuotas Pinnacle)	Float64	H: NaN, D: NaN, A: NaN

WHH, WHD, WHA (Cuotas William Hill)	Float64	H: 1.70, D: 3.30, A: 4.33
SJH, SJD, SJA (Cuotas Stan James)	Float64	H: 1.90, D: 3.30, A: 4.00
VCH, VCD, VCA (Cuotas VC Bet)	Float64	H: 1.65, D: 3.40, A: 4.50
GBH, GBD, GBA (Cuotas Gamebookers)	Float64	H: 1.78, D: 3.25, A: 4.00
BSH, BSD, BSA (Cuotas Blue Square)	Float64	H: 1.73, D: 3.40, A: 4.20